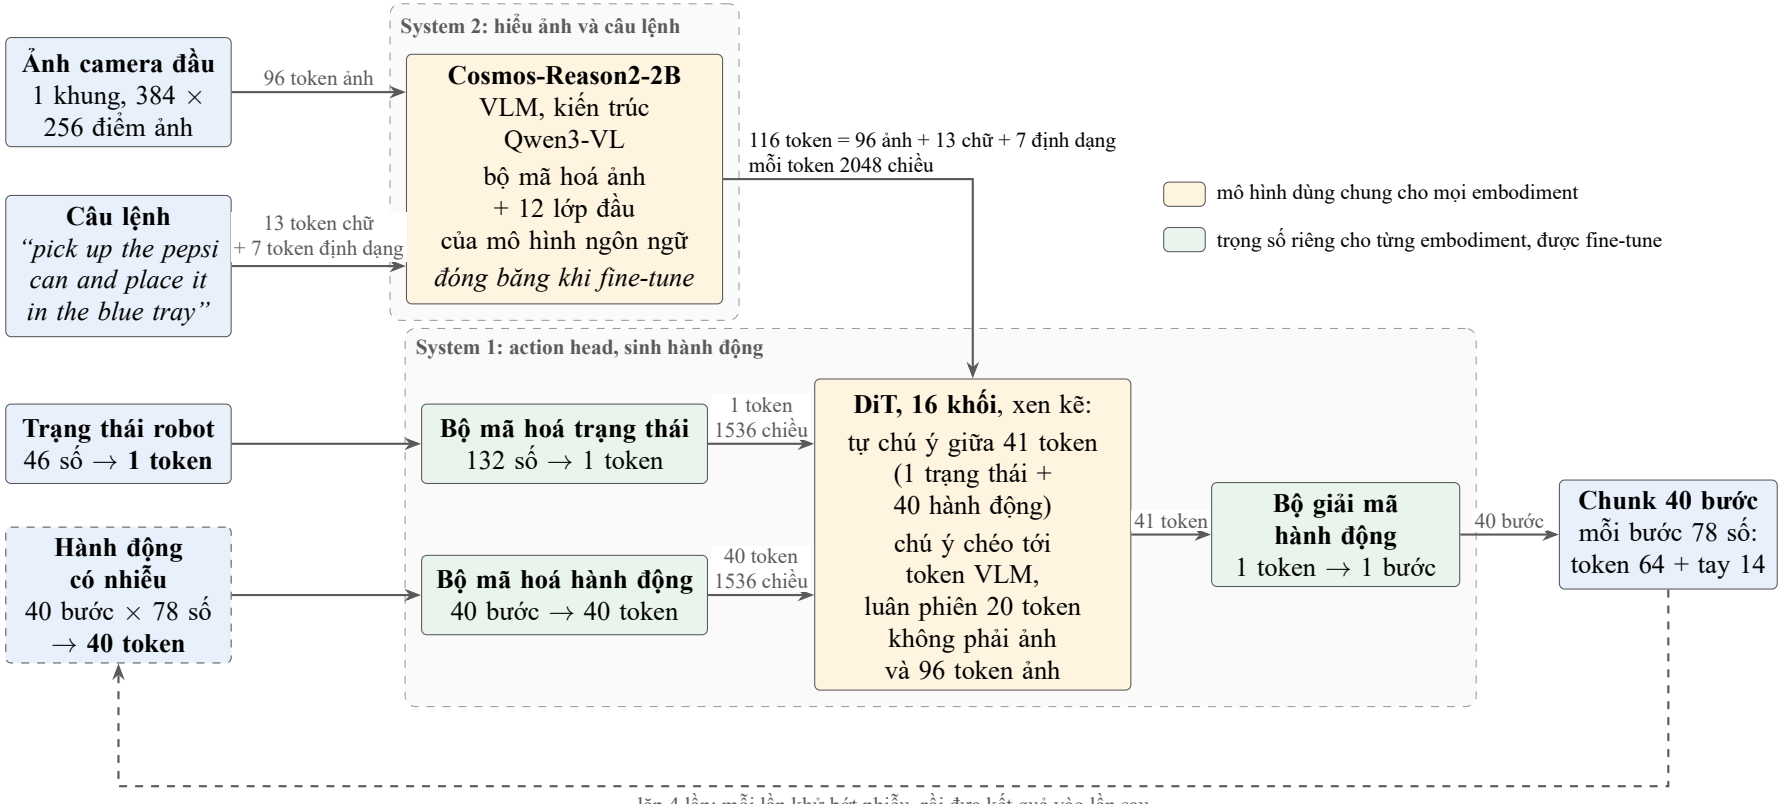
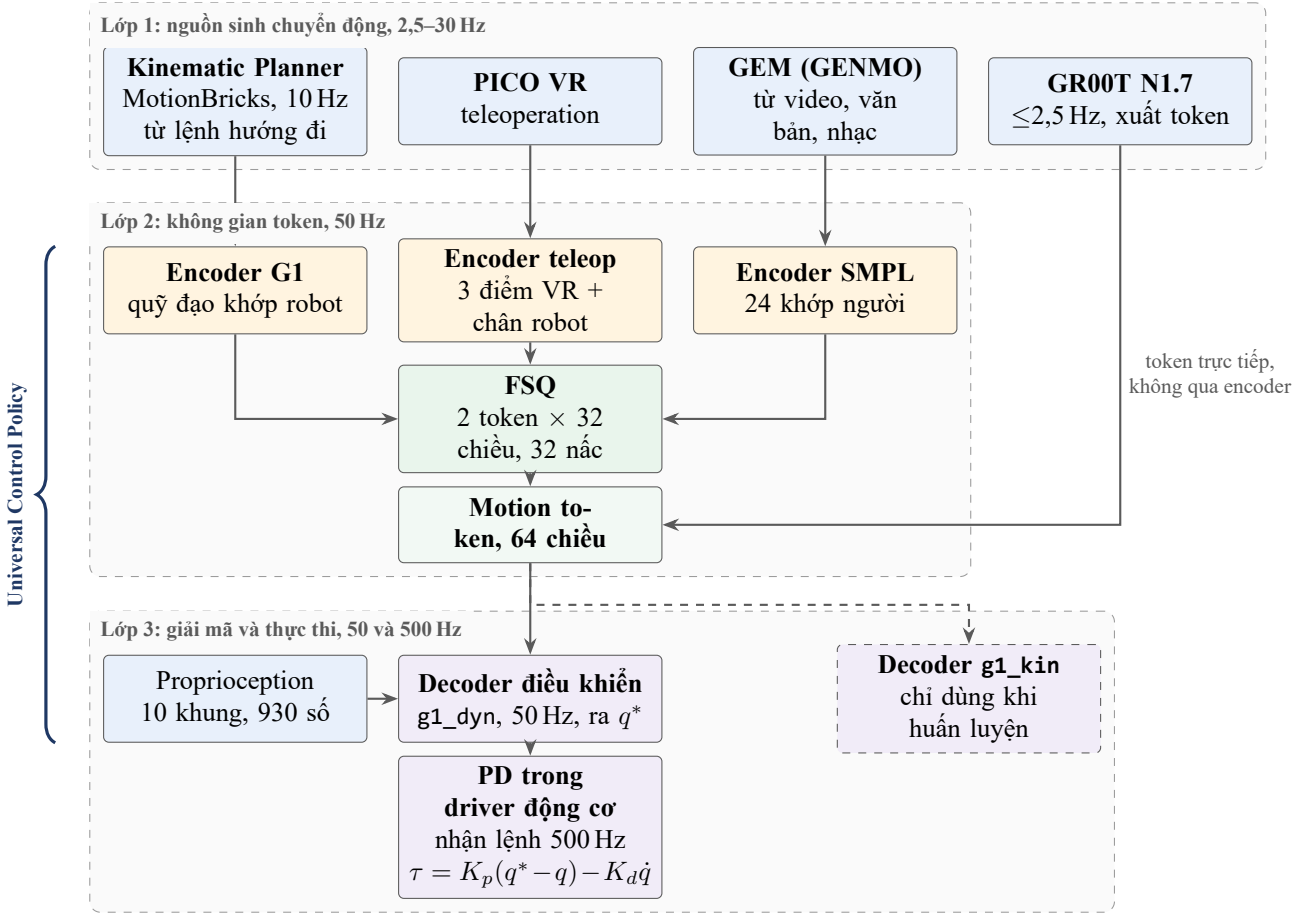
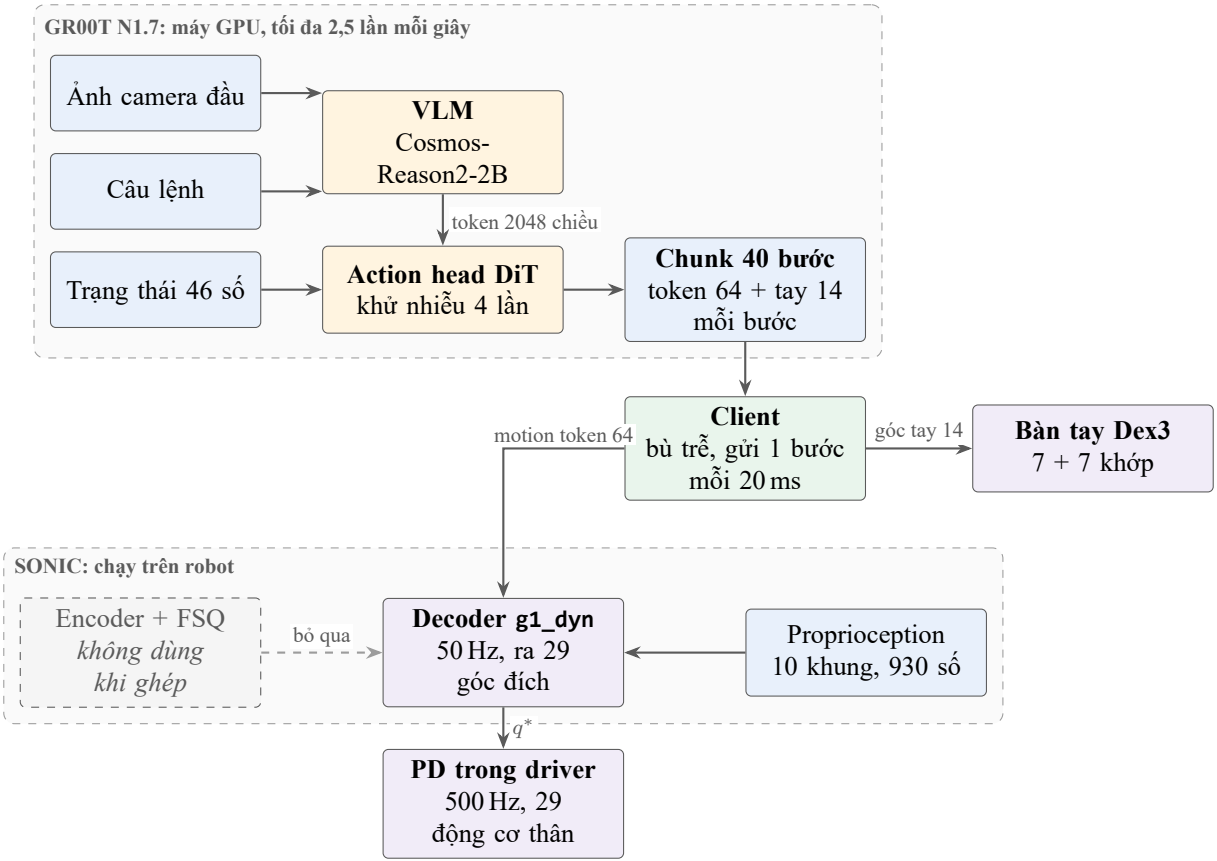
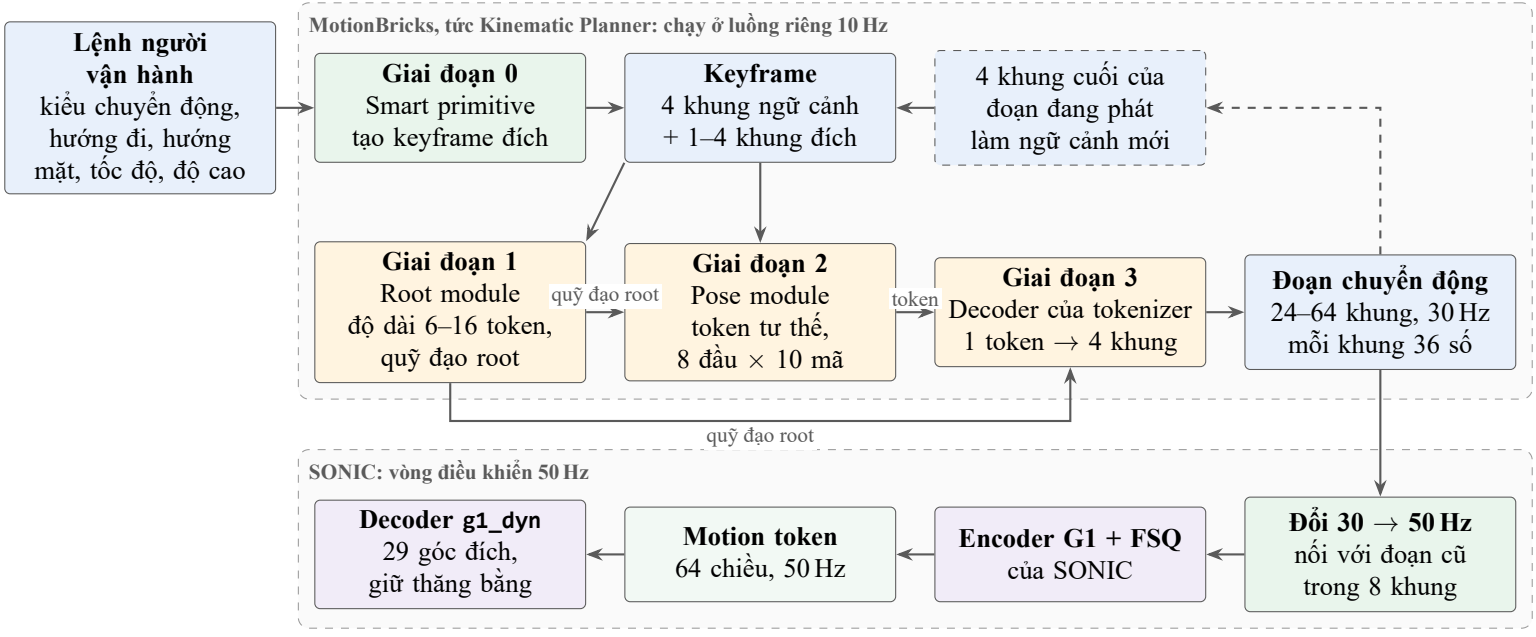
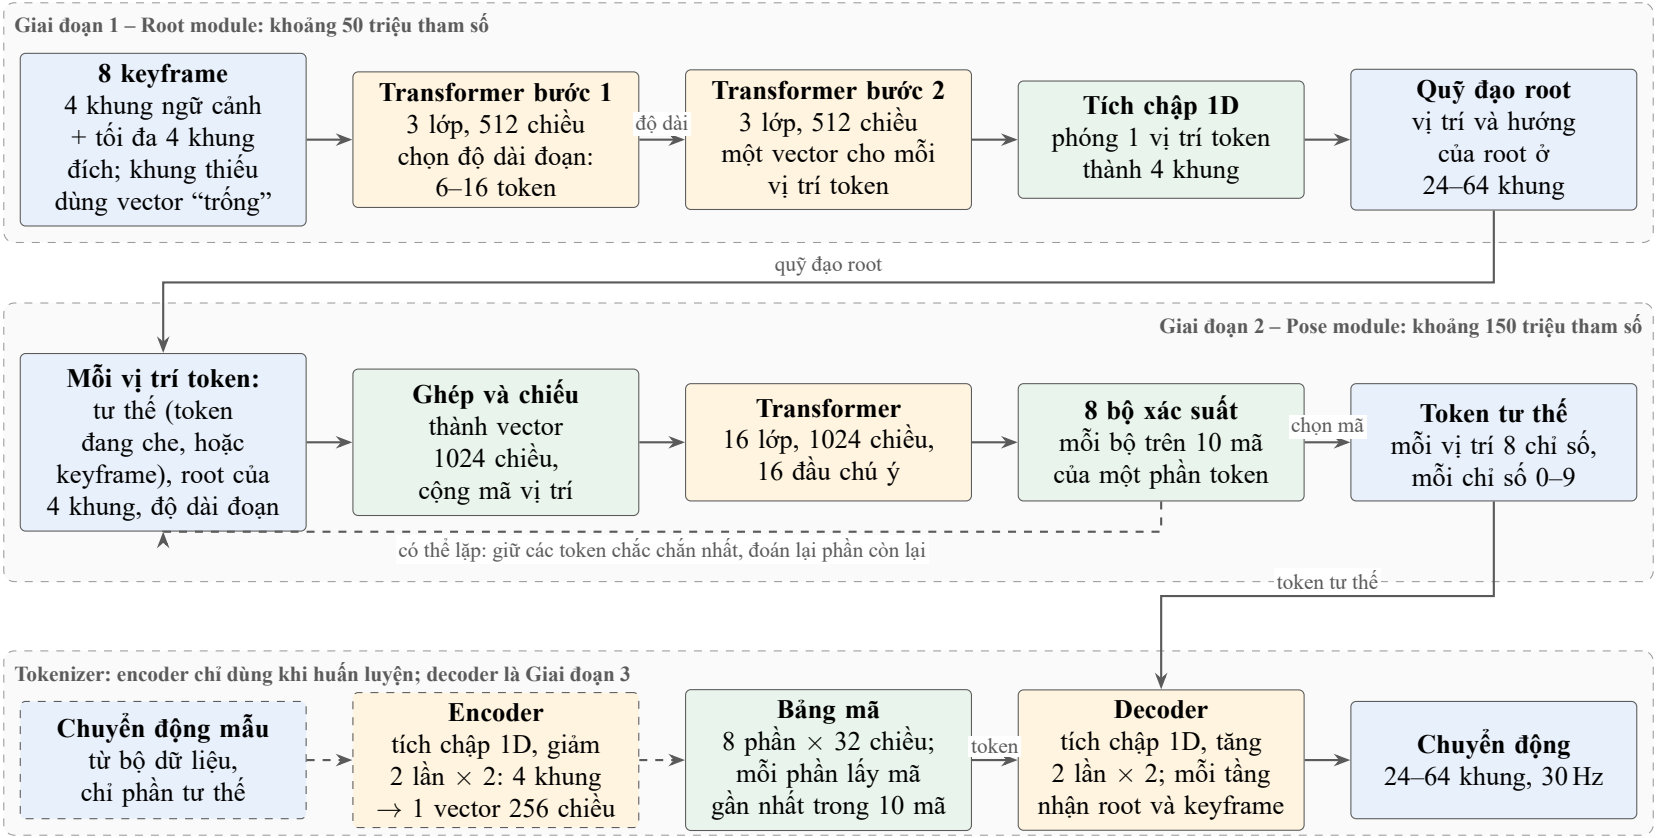
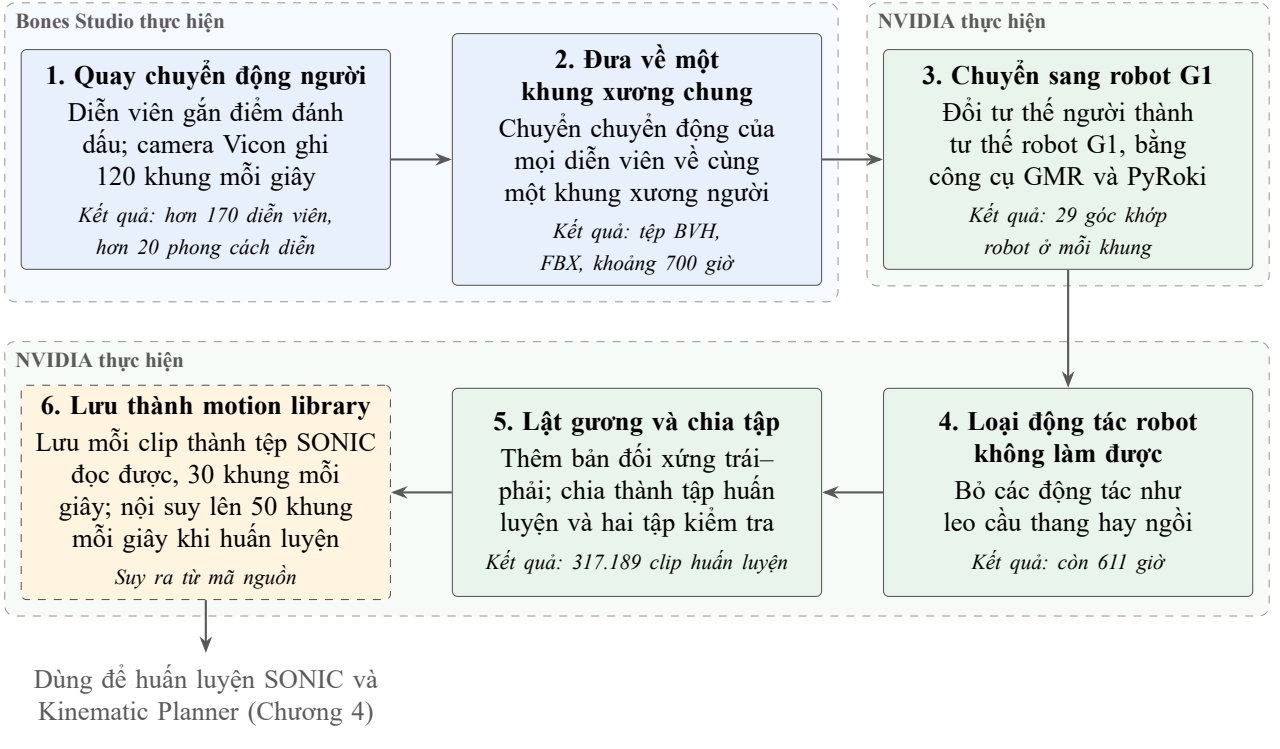

System 2: hiểu ảnh và câu lệnh
Ảnh camera đầu
1 khung, 384 × 256 điểm ảnh
96 token ảnh
Cosmos-Reason2-2B
VLM, kiến trúc Qwen3-VL
bộ mã hoá ảnh + 12 lớp đầu của mô hình ngôn ngữ
đóng băng khi fine-tune
Câu lệnh
"pick up the pepsi can and place it in the blue tray"
13 token chữ + 7 token định dạng
116 token = 96 ảnh + 13 chữ + 7 định dạng
mỗi token 2048 chiều
mô hình dùng chung cho mọi embodiment
trọng số riêng cho từng embodiment, được fine-tune
System 1: action head, sinh hành động
Trạng thái robot
46 số → 1 token
Bộ mã hoá trạng thái
132 số → 1 token
1 token
1536 chiều
Hành động có nhiễu
40 bước × 78 số
→ 40 token
Bộ mã hoá hành động
40 bước → 40 token
40 token
1536 chiều
DiT, 16 khối, xen kẽ:
tự chú ý giữa 41 token (1 trạng thái + 40 hành động)
chú ý chéo tới token VLM, luân phiên 20 token không phải ảnh và 96 token ảnh
41 token
Bộ giải mã hành động
1 token → 1 bước
40 bước
Chunk 40 bước
mỗi bước 78 số:
token 64 + tay 14
lặp 4 lần: mỗi lần khử bớt nhiễu, rồi đưa kết quả vào lần sau


Lớp 1: nguồn sinh chuyển động, 2,5–30 Hz
Kinematic Planner
MotionBricks, 10 Hz
từ lệnh hướng đi
PICO VR
teleoperation
GEM (GENMO)
từ video, văn
bản, nhạc
GR00T N1.7
≤2,5 Hz, xuất token
Lớp 2: không gian token, 50 Hz
Encoder G1
quỹ đạo khớp robot
Encoder teleop
3 điểm VR +
chân robot
Encoder SMPL
24 khớp người
FSQ
2 token × 32
chiều, 32 nấc
Motion to-
ken, 64 chiều
token trực tiếp,
không qua encoder
Universal Control Policy
Lớp 3: giải mã và thực thi, 50 và 500 Hz
Proprioception
10 khung, 930 số
Decoder điều khiển
g1_dyn, 50 Hz, ra q^*
Decoder g1_kin
chỉ dùng khi
huấn luyện
PD trong
driver động cơ
nhận lệnh 500 Hz
$\tau = K_p(q^* - q) - K_d\dot{q}$

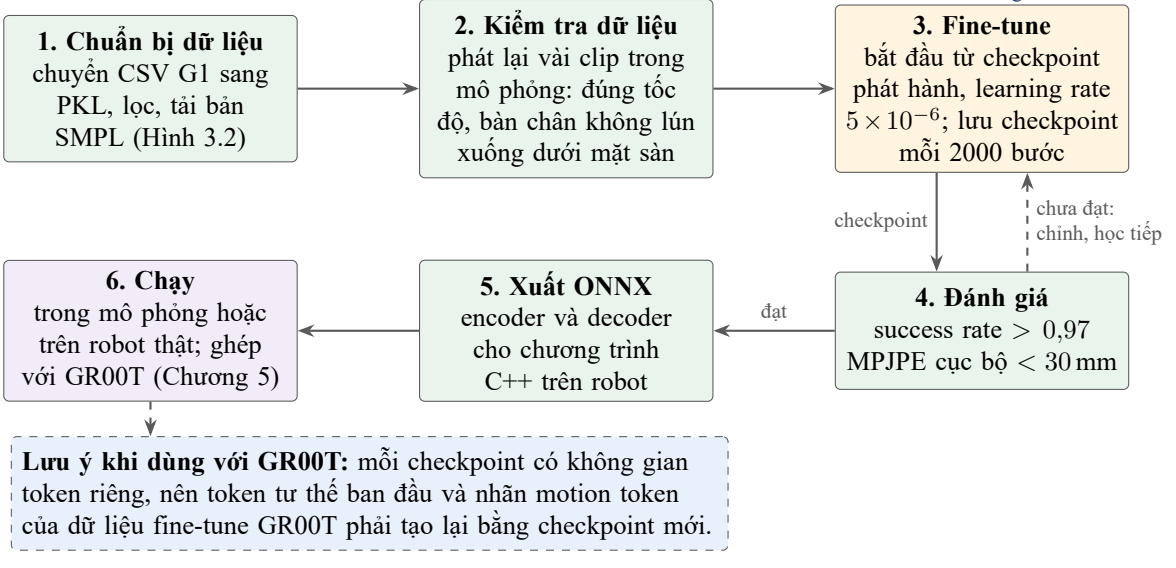

GR00T N1.7: máy GPU, tối đa 2,5 lần mỗi giây
Ảnh camera đầu
Câu lệnh
Trạng thái 46 số
VLM
Cosmos-
Reason2-2B
token 2048 chiều
Action head DiT
khử nhiễu 4 lần
Chunk 40 bước
token 64 + tay 14
mỗi bước
Client
bù trễ, gửi 1 bước
mỗi 20 ms
motion token 64
góc tay 14
Bàn tay Dex3
7 + 7 khớp
SONIC: chạy trên robot
Encoder + FSQ
không dùng
khi ghép
bỏ qua
Decoder g1_dyn
50 Hz, ra 29
góc đích
Proprioception
10 khung, 930 số
q*
PD trong driver
500 Hz, 29
động cơ thân

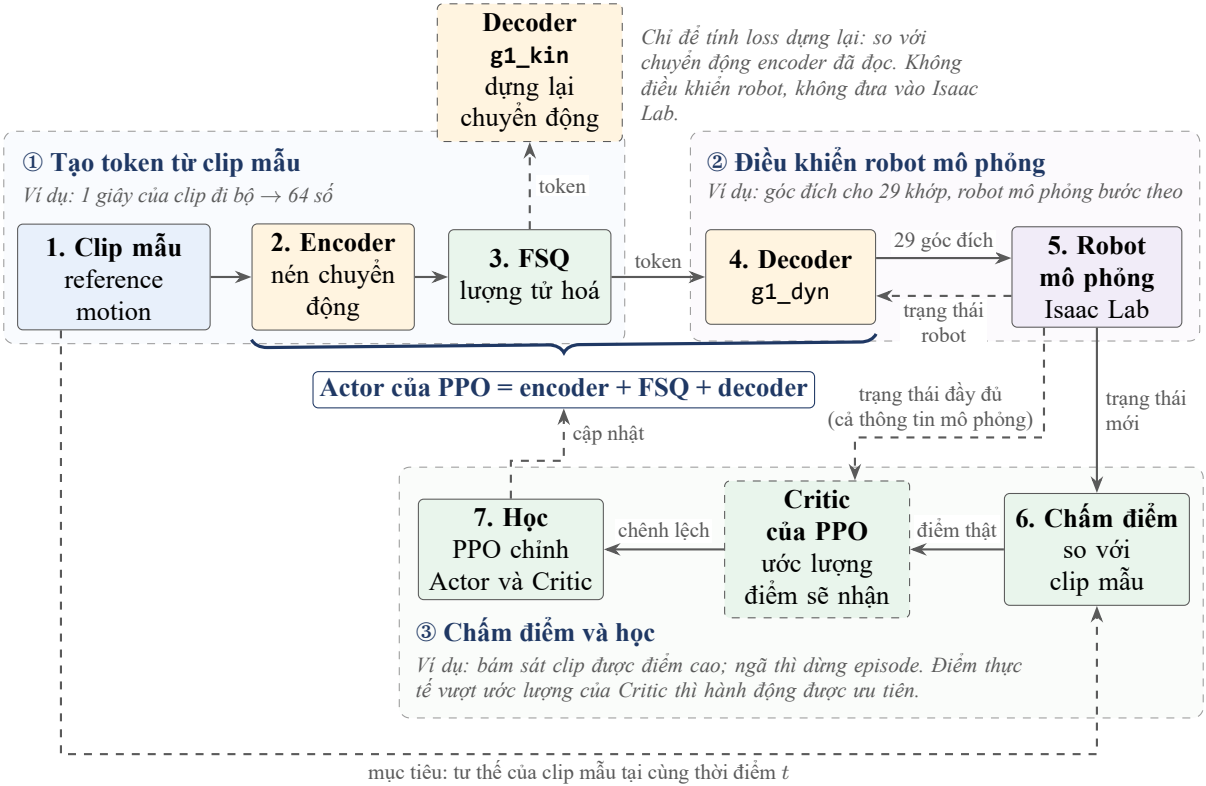

Lệnh người vận hành
kiểu chuyển động, hướng đi, hướng mặt, tốc độ, độ cao
MotionBricks, tức Kinematic Planner: chạy ở luồng riêng 10 Hz
Giai đoạn 0
Smart primitive tạo keyframe đích
Keyframe
4 khung ngữ cảnh + 1–4 khung đích
4 khung cuối của đoạn đang phát làm ngữ cảnh mới
Giai đoạn 1
Root module
độ dài 6–16 token, quỹ đạo root
quỹ đạo root
Giai đoạn 2
Pose module
token tư thế, 8 đầu × 10 mã
token
Giai đoạn 3
Decoder của tokenizer
1 token → 4 khung
Đoạn chuyển động
24–64 khung, 30 Hz
mỗi khung 36 số
quỹ đạo root
SONIC: vòng điều khiển 50 Hz
Decoder g1_dyn
29 góc đích, giữ thăng bằng
Motion token
64 chiều, 50 Hz
Encoder G1 + FSQ
của SONIC
Đổi 30 → 50 Hz
nối với đoạn cũ trong 8 khung

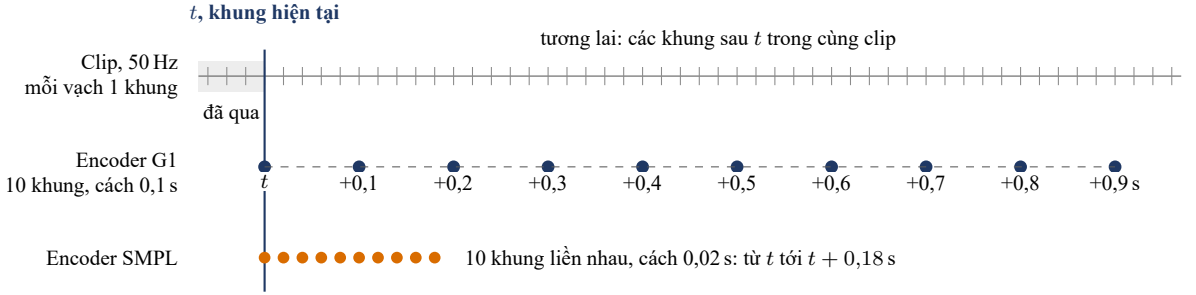

Giai đoạn 1 – Root module: khoảng 50 triệu tham số
8 keyframe
4 khung ngữ cảnh
+ tối đa 4 khung
đích; khung thiếu
dùng vector "trống"
Transformer bước 1
3 lớp, 512 chiều
chọn độ dài đoạn:
6–16 token
độ dài
Transformer bước 2
3 lớp, 512 chiều
một vector cho mỗi
vị trí token
Tích chập 1D
phóng 1 vị trí token
thành 4 khung
Quỹ đạo root
vị trí và hướng
của root ở
24–64 khung
quỹ đạo root
Giai đoạn 2 – Pose module: khoảng 150 triệu tham số
Mỗi vị trí token:
tư thế (token
đang che, hoặc
keyframe), root của
4 khung, độ dài đoạn
Ghép và chiếu
thành vector
1024 chiều,
cộng mã vị trí
Transformer
16 lớp, 1024 chiều,
16 đầu chú ý
8 bộ xác suất
mỗi bộ trên 10 mã
của một phần token
chọn mã
Token tư thế
mỗi vị trí 8 chỉ số,
mỗi chỉ số 0–9
có thể lặp: giữ các token chắc chắn nhất, đoán lại phần còn lại
token tư thế
Tokenizer: encoder chỉ dùng khi huấn luyện; decoder là Giai đoạn 3
Chuyển động mẫu
từ bộ dữ liệu,
chỉ phần tư thế
Encoder
tích chập 1D, giảm
2 lần × 2: 4 khung
→ 1 vector 256 chiều
Bảng mã
8 phần × 32 chiều;
mỗi phần lấy mã
gần nhất trong 10 mã
token
Decoder
tích chập 1D, tăng
2 lần × 2; mỗi tầng
nhận root và keyframe
Chuyển động
24–64 khung, 30 Hz


Bones Studio thực hiện
1. Quay chuyển động người
Diễn viên gắn điểm đánh dấu; camera Vicon ghi 120 khung mỗi giây
Kết quả: hơn 170 diễn viên, hơn 20 phong cách diễn
2. Đưa về một khung xương chung
Chuyển chuyển động của mọi diễn viên về cùng một khung xương người
Kết quả: tệp BVH, FBX, khoảng 700 giờ
NVIDIA thực hiện
3. Chuyển sang robot G1
Đổi tư thế người thành tư thế robot G1, bằng công cụ GMR và PyRoki
Kết quả: 29 góc khớp robot ở mỗi khung
4. Loại động tác robot không làm được
Bỏ các động tác như leo cầu thang hay ngồi
Kết quả: còn 611 giờ
NVIDIA thực hiện
5. Lật gương và chia tập
Thêm bản đối xứng trái–phải; chia thành tập huấn luyện và hai tập kiểm tra
Kết quả: 317.189 clip huấn luyện
6. Lưu thành motion library
Lưu mỗi clip thành tệp SONIC đọc được, 30 khung mỗi giây; nội suy lên 50 khung mỗi giây khi huấn luyện
Suy ra từ mã nguồn
Dùng để huấn luyện SONIC và Kinematic Planner (Chương 4)

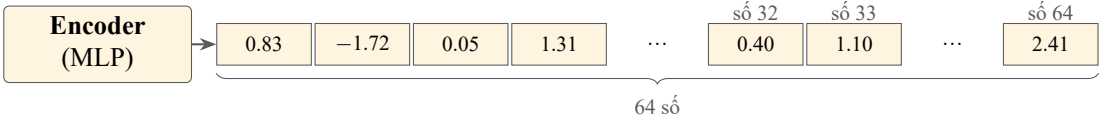

Phần robot: nhóm thực hiện tự chuyển định dạng và lọc
Dữ liệu tải về
Chuyển động robot G1 của Bones-SEED, tệp CSV, 120 khung mỗi giây
142.220 clip
Bước 1. Chuyển định dạng
Đổi sang định dạng SONIC đọc được (motion library), giảm còn 30 khung mỗi giây
Kết quả bước 1
Dữ liệu robot ở định dạng motion library, mỗi clip một tệp PKL
142.220 tệp PKL
Bước 2. Lọc
Bỏ các clip robot không làm được, ví dụ động tác ngồi hay leo cầu thang
Kết quả bước 2
Dữ liệu robot đã lọc, vẫn ở dạng tệp PKL
129.785 tệp PKL, 264,5 giờ
dữ liệu robot
Phần người: NVIDIA đã xử lý sẵn, chỉ cần tải về
Dữ liệu NVIDIA phát hành
Chuyển động người dạng SMPL của các clip Bones-SEED
khoảng 30 GB
Bước 3. Tải về
Tải từ Hugging Face và giải nén; không cần xử lý thêm
Kết quả bước 3
Dữ liệu người dạng SMPL, tệp PKL cùng tên với tệp robot
khoảng 131 nghìn tệp PKL
dữ liệu người
ghép với dữ liệu robot theo tên clip
Bước 4. Fine-tune SONIC
Huấn luyện tiếp từ checkpoint đã phát hành, trên dữ liệu robot và người của cùng các clip
dữ liệu
bước xử lý
huấn luyện


một bước bên trong: Hình 4.1
1. Chuẩn bị dữ liệu
chuyển CSV G1 sang PKL, lọc, tải bản SMPL (Hình 3.2)
2. Kiểm tra dữ liệu
phát lại vài clip trong mô phỏng: đúng tốc độ, bàn chân không lún xuống dưới mặt sàn
3. Fine-tune
bắt đầu từ checkpoint phát hành, learning rate 5×10^{-6}; lưu checkpoint mỗi 2000 bước
checkpoint
chưa đạt: chỉnh, học tiếp
4. Đánh giá
success rate $> 0{,}97$
MPJPE cục bộ $< 30\,\text{mm}$
đạt
5. Xuất ONNX
encoder và decoder cho chương trình C++ trên robot
6. Chạy
trong mô phỏng hoặc trên robot thật; ghép với GR00T (Chương 5)
Lưu ý khi dùng với GR00T: mỗi checkpoint có không gian token riêng, nên token tư thế ban đầu và nhãn motion token của dữ liệu fine-tune GR00T phải tạo lại bằng checkpoint mới.


Decoder
g1_kin
dựng lại
chuyển động
Chỉ để tính loss dựng lại: so với chuyển động encoder đã đọc. Không điều khiển robot, không đưa vào Isaac Lab.
① Tạo token từ clip mẫu
Ví dụ: 1 giây của clip đi bộ → 64 số
token
② Điều khiển robot mô phỏng
Ví dụ: góc đích cho 29 khớp, robot mô phỏng bước theo
1. Clip mẫu
reference
motion
2. Encoder
nén chuyển
động
3. FSQ
lượng tử hoá
token
4. Decoder
g1_dyn
29 góc đích
5. Robot
mô phỏng
Isaac Lab
trạng thái
robot
Actor của PPO = encoder + FSQ + decoder
trạng thái đầy đủ
(cả thông tin mô phỏng)
trạng thái
mới
cập nhật
7. Học
PPO chỉnh
Actor và Critic
chênh lệch
Critic
của PPO
ước lượng
điểm sẽ nhận
điểm thật
6. Chấm điểm
so với
clip mẫu
③ Chấm điểm và học
Ví dụ: bám sát clip được điểm cao; ngã thì dừng episode. Điểm thực tế vượt ước lượng của Critic thì hành động được ưu tiên.
mục tiêu: tư thế của clip mẫu tại cùng thời điểm t


t, khung hiện tại
tương lai: các khung sau t trong cùng clip
Clip, 50 Hz
mỗi vạch 1 khung
đã qua
Encoder G1
10 khung, cách 0,1 s
t
+0,1
+0,2
+0,3
+0,4
+0,5
+0,6
+0,7
+0,8
+0,9 s
Encoder SMPL
10 khung liền nhau, cách 0,02 s: từ t tới $t + 0{,}18$ s

Bước 1. Encoder đọc khoảng 1 giây chuyển động, xuất ra 64 số thực chưa làm tròn

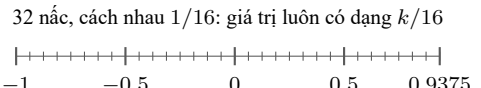


Bước 2. Xếp 64 số thành 2 hàng × 32 ô; mỗi hàng là một token

	ô 1	ô 2	ô 3	ô 4	⋯	ô 32
Token 1 (số thứ 1–32)	0.83	−1.72	0.05	1.31	⋯	0.40
Token 2 (số thứ 33–64)	1.10	0.22	−0.67	−0.15	⋯	2.41

Bước 3. FSQ làm tròn *từng ô* về 1 trong 32 nấc cố định

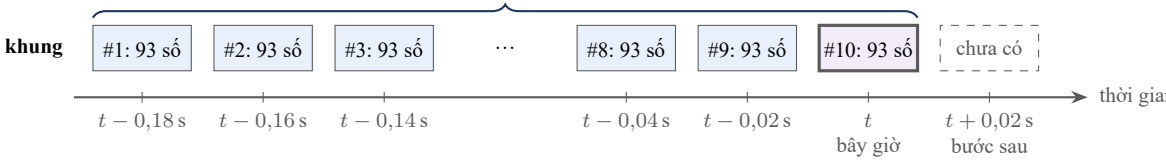
Token 1	0.6875	−0.9375	0.0625	0.8125	⋯	0.375
Token 2	0.8125	0.1875	−0.5625	−0.125	⋯	0.9375



Bước 4. Nối 2 hàng thành 1 dãy 64 số: đây là motion token mà decoder nhận và GR00T học dự đoán



(a) Decoder đọc 10 khung gần nhất, mỗi khung cách nhau 0,02 s



(b) Một khung gồm 93 số

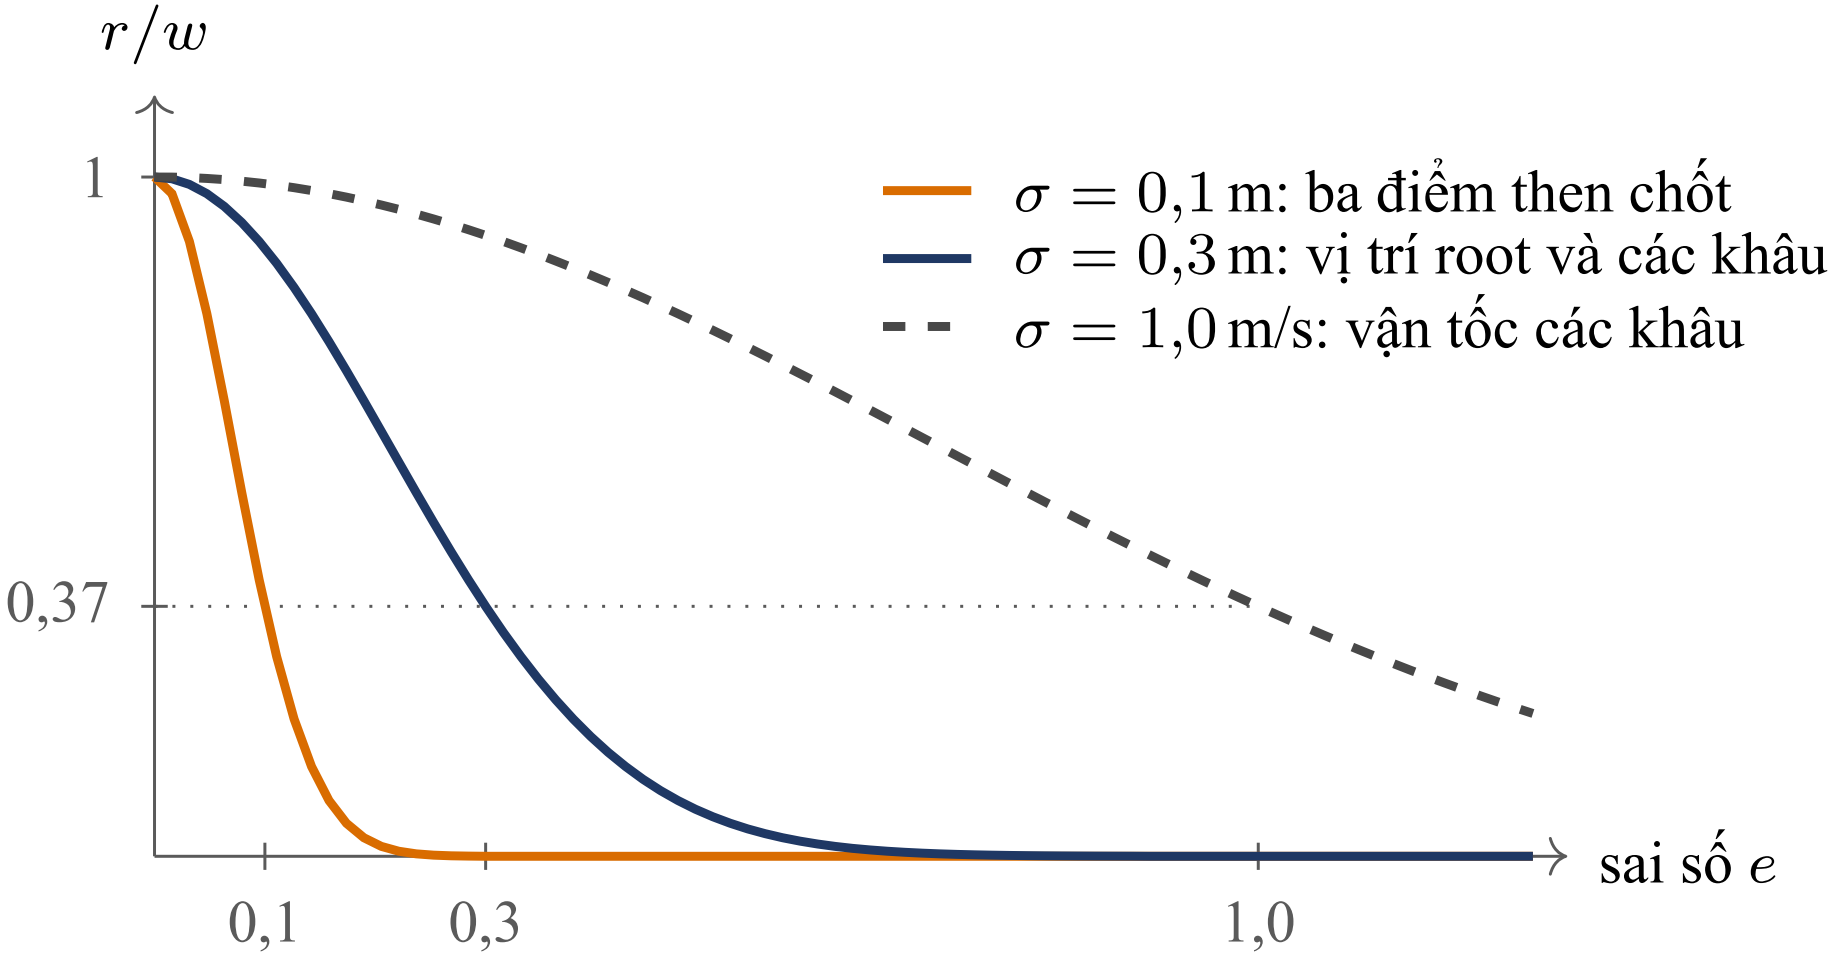
vận tốc góc thân **3** + góc 29 khớp **29** + vận tốc 29 khớp **29** + lệnh decoder ở bước trước **29** + hướng trọng lực **3** = **93** số

(c) Đầu vào của decoder: mỗi đại lượng lấy đủ 10 khung rồi đặt liền nhau, theo cấu hình của checkpoint

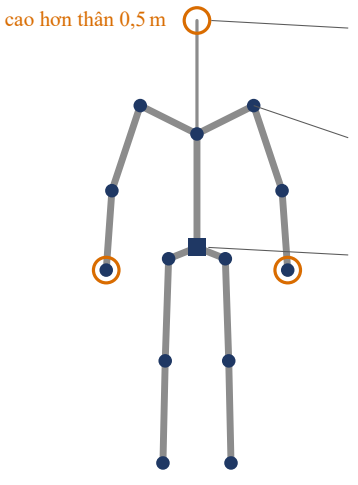
toàn bộ đầu vào của decoder `g1_dyn`: 64 + 930 = **994** số

Motion token **64**	Vận tốc góc thân $3 \times 10 = \mathbf{30}$	Góc 29 khớp $29 \times 10 = \mathbf{290}$	Vận tốc 29 khớp $29 \times 10 = \mathbf{290}$	Lệnh decoder ở bước trước $29 \times 10 = \mathbf{290}$	Hướng trọng lực $3 \times 10 = \mathbf{30}$

lịch sử 10 khung: 30 + 290 + 290 + 290 + 30 = **930**
cũng bằng 10 khung × 93 số = **930**


r/w
1
0,37
0,1
0,3
1,0
sai số e
$\sigma = 0{,}1$ m: ba điểm then chốt
$\sigma = 0{,}3$ m: vị trí root và các khâu
$\sigma = 1{,}0$ m/s: vận tốc các khâu

(a) Reward: so với reference motion ở ba mức



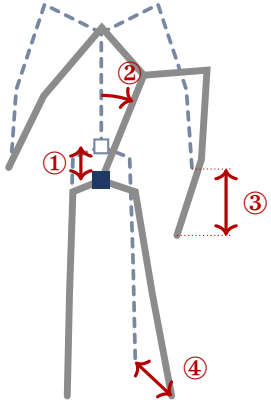
○ **3 điểm then chốt**, trong hệ root
$w = 2{,}0$, $\sigma = 0{,}1$ m

• **14 khâu**: vị trí, hướng (tư thế), vận tốc dài, vận tốc góc
$w = 1{,}0$ mỗi loại

■ **root** (pelvis): vị trí, hướng trong hệ thế giới, $w = 0{,}5$ mỗi loại

phạt: hành động giật, vượt giới hạn khớp, chạm vật sai khâu, rung cổ tay và đầu, gia tốc cổ chân lớn

(b) Termination: dừng episode khi lệch quá xa



— reference motion ▬ robot

① chiều cao pelvis lệch $> 0{,}15$ m

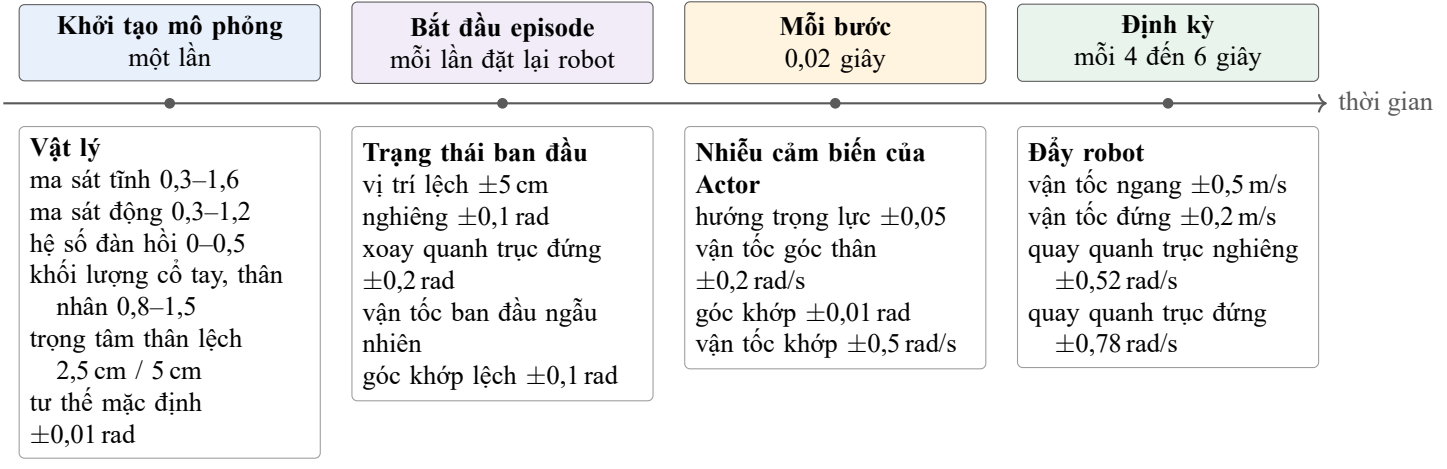
② hướng pelvis lệch $>$ khoảng 26°

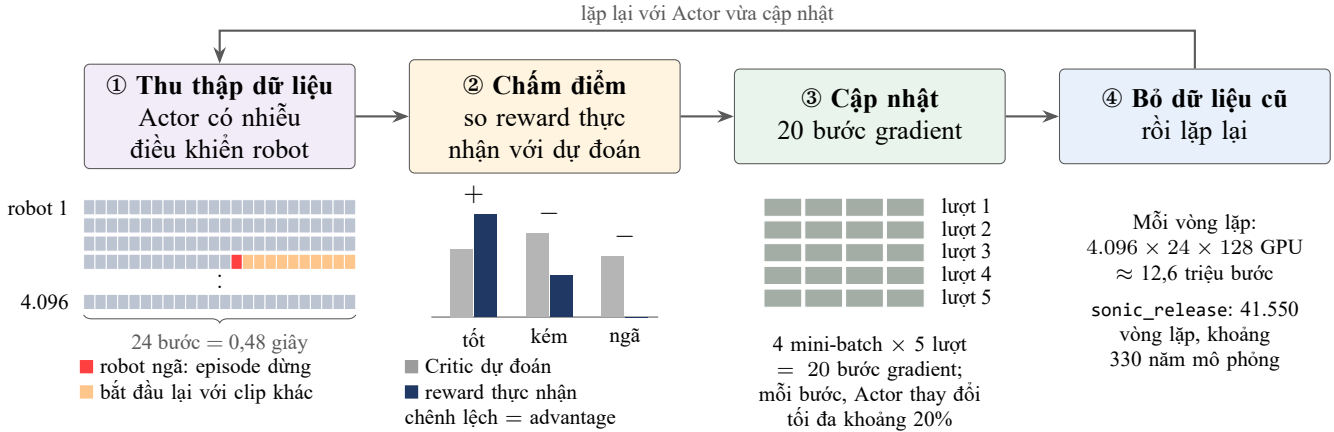
③ chiều cao cổ chân hoặc cổ tay lệch $> 0{,}15$ m

④ vị trí bàn chân lệch $> 0{,}2$ m

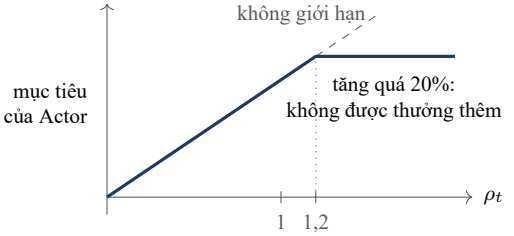
Clip ở tư thế thấp (pelvis dưới 0,5 m): ngưỡng ① và ③ nới lên 0,75 m.

Hết clip: kết thúc bình thường, không tính là thất bại.

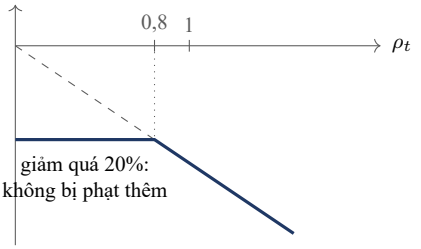

Khởi tạo mô phỏng
một lần
Bắt đầu episode
mỗi lần đặt lại robot
Mỗi bước
0,02 giây
Định kỳ
mỗi 4 đến 6 giây
thời gian
Vật lý
ma sát tĩnh 0,3–1,6
ma sát động 0,3–1,2
hệ số đàn hồi 0–0,5
khối lượng cổ tay, thân nhân 0,8–1,5
trọng tâm thân lệch 2,5 cm / 5 cm
tư thế mặc định ±0,01 rad
Trạng thái ban đầu
vị trí lệch ±5 cm
nghiêng ±0,1 rad
xoay quanh trục đứng ±0,2 rad
vận tốc ban đầu ngẫu nhiên
góc khớp lệch ±0,1 rad
Nhiễu cảm biến của Actor
hướng trọng lực ±0,05
vận tốc góc thân ±0,2 rad/s
góc khớp ±0,01 rad
vận tốc khớp ±0,5 rad/s
Đẩy robot
vận tốc ngang ±0,5 m/s
vận tốc đứng ±0,2 m/s
quay quanh trục nghiêng ±0,52 rad/s
quay quanh trục đứng ±0,78 rad/s

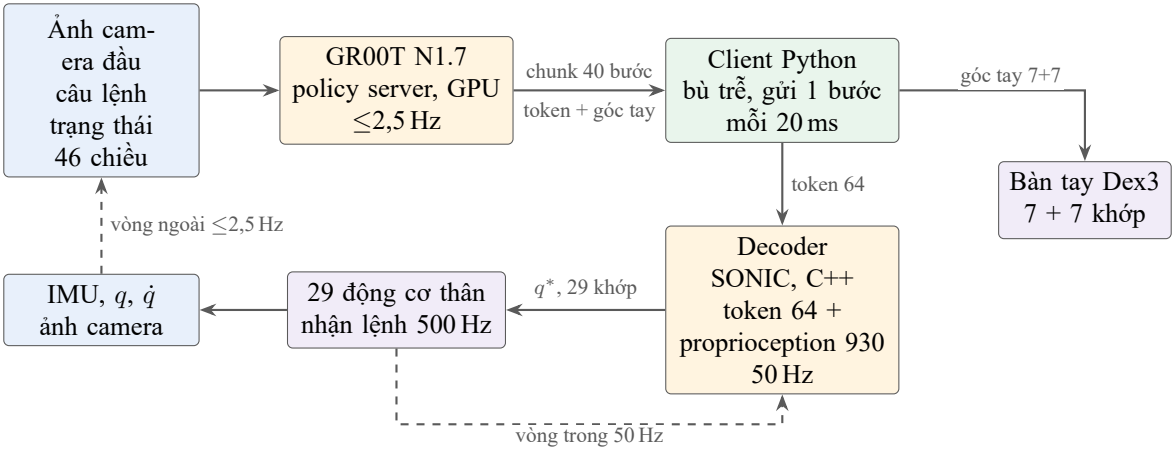

lặp lại với Actor vừa cập nhật
① Thu thập dữ liệu
Actor có nhiều
điều khiển robot
② Chấm điểm
so reward thực
nhận với dự đoán
③ Cập nhật
20 bước gradient
④ Bỏ dữ liệu cũ
rồi lặp lại
robot 1
4.096
24 bước = 0,48 giây
robot ngã: episode dừng
bắt đầu lại với clip khác
+
−
−
tốt
kém
ngã
Critic dự đoán
reward thực nhận
chênh lệch = advantage
lượt 1
lượt 2
lượt 3
lượt 4
lượt 5
4 mini-batch × 5 lượt
= 20 bước gradient;
mỗi bước, Actor thay đổi
tối đa khoảng 20%
Mỗi vòng lặp:
4.096 × 24 × 128 GPU
≈ 12,6 triệu bước
sonic_release: 41.550
vòng lặp, khoảng
330 năm mô phỏng

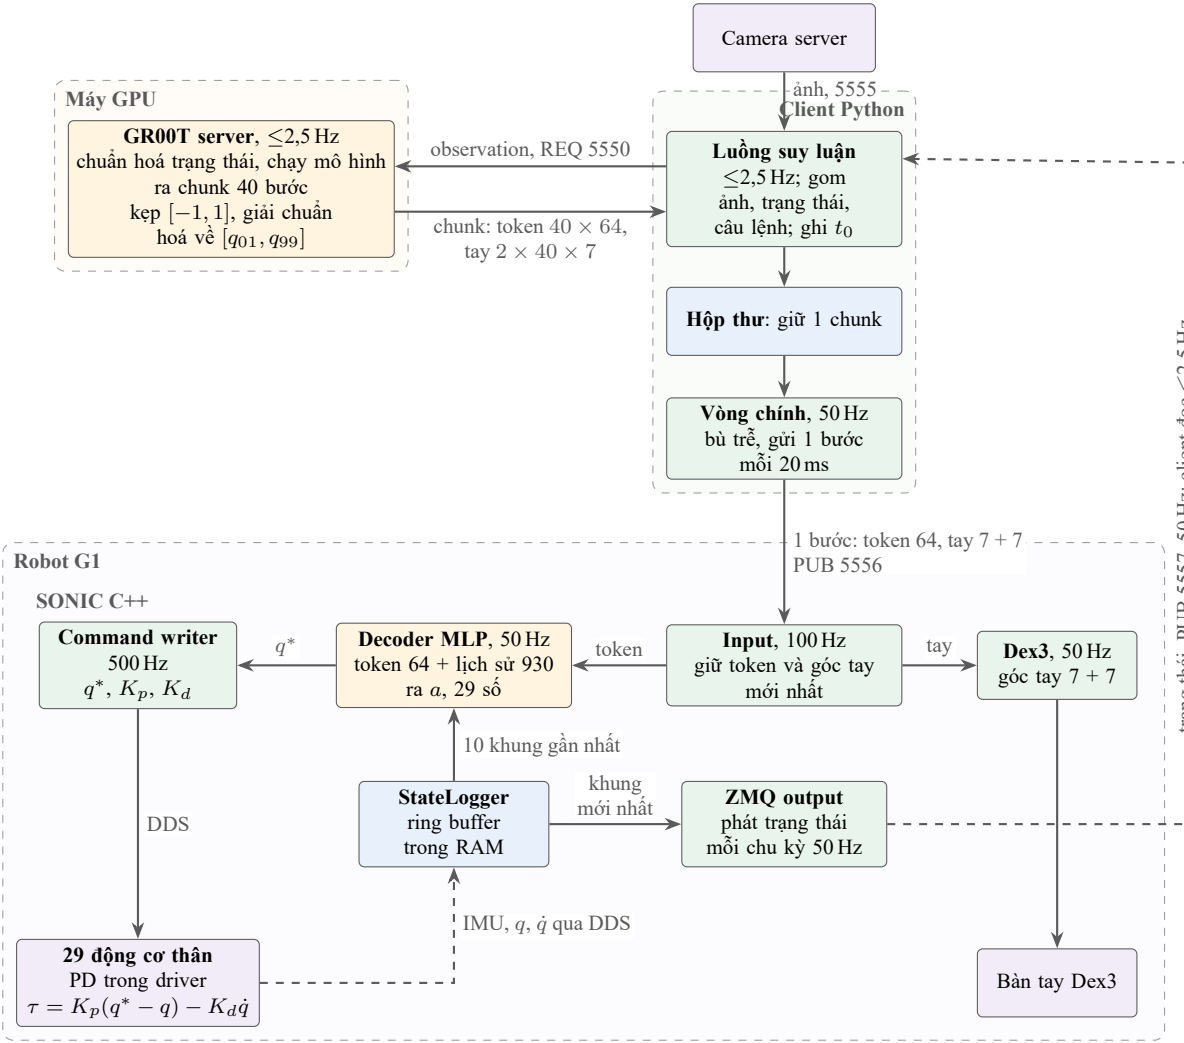
(a) $\hat{A}_t > 0$: hành động tốt hơn dự đoán

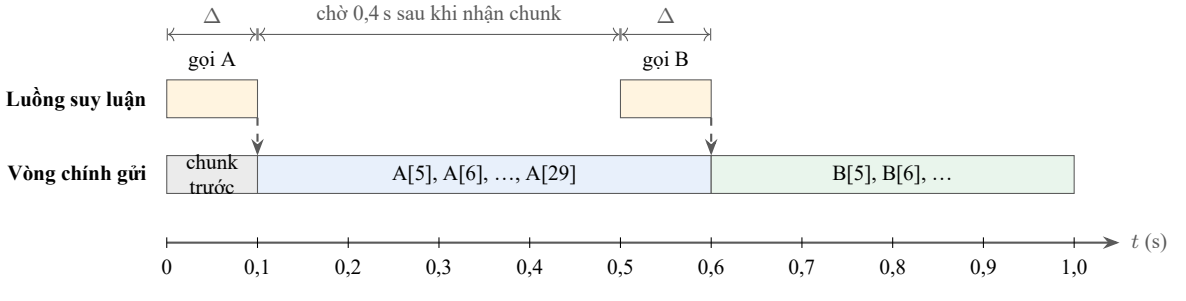


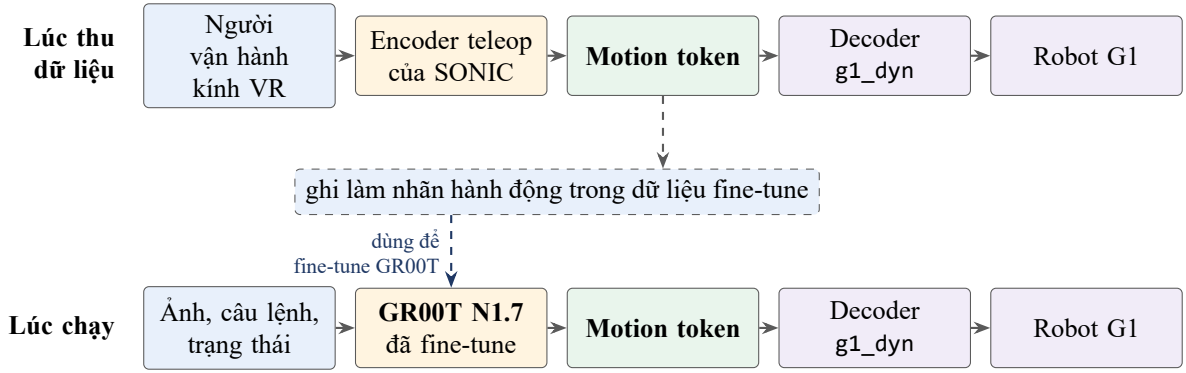
(b) $\hat{A}_t < 0$: hành động kém hơn dự đoán




Ảnh cam-
era đầu
câu lệnh
trạng thái
46 chiều
GR00T N1.7
policy server, GPU
≤2,5 Hz
chunk 40 bước
token + góc tay
Client Python
bù trễ, gửi 1 bước
mỗi 20 ms
góc tay 7+7
Bàn tay Dex3
7 + 7 khớp
token 64
Decoder
SONIC, C++
token 64 +
proprioception 930
50 Hz
q*, 29 khớp
29 động cơ thân
nhận lệnh 500 Hz
IMU, q, q̇
ảnh camera
vòng ngoài ≤2,5 Hz
vòng trong 50 Hz


Camera server
ảnh, 5555
Client Python
Máy GPU
GR00T server, ≤2,5 Hz
chuẩn hoá trạng thái, chạy mô hình
ra chunk 40 bước
kẹp [−1, 1], giải chuẩn
hoá về [q01, q99]
observation, REQ 5550
chunk: token 40 × 64,
tay 2 × 40 × 7
Luồng suy luận
≤2,5 Hz; gom
ảnh, trạng thái,
câu lệnh; ghi t0
Hộp thư: giữ 1 chunk
Vòng chính, 50 Hz
bù trễ, gửi 1 bước
mỗi 20 ms
1 bước: token 64, tay 7 + 7
PUB 5556
trạng thái, PUB 5557, 50 Hz; client đọc ≤2,5 Hz
Robot G1
SONIC C++
Command writer
500 Hz
q*, Kp, Kd
q*
Decoder MLP, 50 Hz
token 64 + lịch sử 930
ra a, 29 số
token
Input, 100 Hz
giữ token và góc tay
mới nhất
tay
Dex3, 50 Hz
góc tay 7 + 7
10 khung gần nhất
DDS
StateLogger
ring buffer
trong RAM
khung
mới nhất
ZMQ output
phát trạng thái
mỗi chu kỳ 50 Hz
IMU, q, q̇ qua DDS
29 động cơ thân
PD trong driver
τ = Kp(q* − q) − Kdq̇
Bàn tay Dex3


Δ
chờ 0,4 s sau khi nhận chunk
Δ
gọi A
gọi B
Luồng suy luận
Vòng chính gửi
chunk trước
A[5], A[6], …, A[29]
B[5], B[6], …
t (s)
0
0,1
0,2
0,3
0,4
0,5
0,6
0,7
0,8
0,9
1,0


Lúc thu dữ liệu
Người vận hành kính VR
Encoder teleop của SONIC
Motion token
Decoder g1_dyn
Robot G1
ghi làm nhãn hành động trong dữ liệu fine-tune
dùng để fine-tune GR00T
Lúc chạy
Ảnh, câu lệnh, trạng thái
GR00T N1.7 đã fine-tune
Motion token
Decoder g1_dyn
Robot G1